

Projet RH Analytics — DataLendo

Analyse SQL des effectifs, de la performance et du turnover de DataLendo, à partir de 4 tables sources fournies par le service RH.

Contenu du dossier

```
SQL/
├─ employees.csv, departements.csv, performances.csv, turnover.csv  (sources)
├─ hr_dataleendo.db          base SQLite construite à partir des CSV
├─ sql/
│   ├─ 01_schema.sql         structure des tables + notes de chargement
│   ├─ 02_questions_business.sql  les 15 requêtes du mail du manager
│   └─ 03_dataset_enrichi.sql  création de la table employees_enrichi
├─ data/
│   └─ employees_enrichi.csv  dataset employés + colonnes dérivées
├─ INSIGHTS.md               synthèse des résultats + recommandations RH
└─ README.md                 ce fichier
```

Toutes les requêtes ont été **réellement exécutées** contre hr_dataleendo.db (SQLite), pas seulement rédigées : les chiffres cités dans INSIGHTS.md et en commentaire de 02_questions_business.sql sont les résultats obtenus.

1. Les tables

Table	Grain	Colonnes clés
employees (1500 lignes)	1 ligne / employé	id_employe, poste, departement_id, date_embauche, date_depart (NULL si actif), salaire
departements (10 lignes)	1 ligne / département	id_departement, nom_departement, manager, budget
performances (18 000 lignes)	1 ligne / évaluation trimestrielle	id_employe, date_evaluation, score (0-100), objectifs_atteints
turnover (200 lignes)	1 ligne / départ	id_employe, date_depart, type_depart (volontaire/involontaire), anciennete

Intégrité vérifiée : tous les id_employe de performances et turnover existent dans employees ; les 200 lignes de turnover correspondent exactement aux 200 employés de employees ayant un date_depart non nul.

2. Transformations et particularités des données

- **Encodage** : departements.csv est encodé en **Windows-1252** (cp1252), pas en UTF-8 — les accents (« Opérations », « Fatou Traoré », « Direction Générale ») sont corrompus si le fichier est lu en UTF-8 brut. Les 3 autres CSV sont en UTF-8. Voir la note de conversion dans 01_schema.sql.

- **Booléens** : performances.objectifs_atteints contient les chaînes True/False (pas 0/1) dans le CSV source ; converties en entier 0/1 au chargement.

- **Dates de départ « futures »** : certaines valeurs de date_depart (dans employees et turnover) sont

postérieures à la date d'exécution de l'analyse. Elles sont néanmoins traitées comme des départs actés (chaque id_employe concerné a une ligne miroir dans turnover.csv), pas comme des départs "à venir" à ignorer — voir hypothèse ci-dessous.

3. Hypothèses posées (à valider avec le service RH)

1. **Date de référence ("aujourd'hui")** : fixée à **2026-07-17** pour tous les calculs relatifs (ancienneté, statut actif, fenêtre "12 derniers mois"). Codée en dur dans les requêtes pour la reproductibilité du livrable ; à remplacer par CURRENT_DATE (ou une variable de session) si les scripts sont rejoués plus tard sur des données rafraîchies.

2. **Employé actif** = date_depart IS NULL. 1300 employés actifs / 1500.

3. **Salaire moyen (Q4), ancienneté (Q5) et distribution ancienneté/poste (Q12)** : calculés sur les employés **actifs uniquement**, pour refléter la masse salariale et la structure d'effectif actuelles plutôt que l'historique.

4. **Taux de turnover par département (Q3)** = départs historiques cumulés / effectif total historique (départs + actifs actuels) du département. C'est un taux "cumulé depuis toujours", pas un taux annualisé, faute de date d'entrée dans le département dans les données.

5. **Cohorte d'embauche (Q9, Q15)** = année de date_embauche.

6. **"3 derniers trimestres" (Q7)** = les 3 valeurs de date_evaluation les plus récentes **présentes dans les données** (calcul dynamique via MAX/ORDER BY ... LIMIT 3, pas une date en dur) : 2024-04-01, 2024-07-01, 2024-10-01.

7. **"Cette année" pour le feedback manquant (Q13)** : le référentiel performances s'arrête en 2024 (aucune ligne 2025/2026). Interprété comme "la dernière année disponible dans les données" (calcul dynamique), sinon la question serait triviale (100% des actifs, faute de données récentes). Résultat : 0 employé actif sans évaluation en 2024 — le dataset couvre 100% des employés chaque année.

8. **Segmentation de performance faible/moyen/élevé (Q14)** : répartition en **terciles** (NTILE(3)) du score moyen par employé, plutôt que des seuils fixes arbitraires. Les scores moyens par employé sont resserrés autour de 74.5 (écart-type 4.2, car chaque employé a 12 évaluations dont la moyenne lisse la variance individuelle) : des seuils fixes auraient été peu discriminants. Seuils obtenus : Faible ≤ 72.8, Moyen 72.8-76.3, Élevé > 76.3.

4. Méthodologie

1. Chargement des 4 CSV dans une base SQLite (hr_dataendo.db) via pandas, avec l'encodage correct par fichier.

2. Écriture et **exécution réelle** de chaque requête des 15 questions business (sql/02_questions_business.sql), validation manuelle de la cohérence des résultats (sommes de contrôle : effectifs par cohorte, par tranche d'ancienneté, par type de départ).

3. Un bug de jointure a été détecté et corrigé pendant les tests : dans le tableau KPI final (Q15), joindre performances directement (12 lignes par employé) avant d'agréger gonflait artificiellement les comptages d'effectifs et de rétention. Corrigé en pré-agrégeant le score moyen par employé dans un CTE avant la jointure finale.

4. Construction de la table employes_enrichi (sql/03_dataset_enrichi.sql) et export vers data/employes_enrichi.csv.

5. Dataset enrichi (`data/employees\_enrichi.csv`)

1500 lignes (1 par employé), colonnes du fichier employees source + 4 colonnes dérivées :

Colonne	Description
statut	Actif / Parti
cohorte_embauche	Année de date_embauche
anciennete_annees	Ancienneté en années (jusqu'à date_depart si parti, sinon jusqu'à la date de référence)
score_moyen	Moyenne de tous les scores de performance de l'employé
categorie_performance	Faible / Moyen / Eleve (tercile du score moyen, cf hypothèse 8)